

臺北捷運人流預測

從模型比較到站型與事件效應分析

3.41 億筆 OD 紀錄 | 119 站 | 2023–2026/05

Sherry

liushuyu1219@gmail.com

2026 年 7 月

摘要

本研究以 2023 年 1 月至 2026 年 5 月、共 3.41 億筆的臺北捷運進出站 OD 紀錄 (119 站 × 1,247 天)，在完全相同的資料切分、一步預測協定與 WAPE 指標下，系統性比較三個世代的預測方法：古典統計 (SARIMAX、逐站 OLS)、機器學習 (LightGBM、RandomForest)、深度學習 (LSTM)，預測每站次日進站量，並回答三個研究問題：不同站型適合的預測工具是否一樣 (a)、OD 路網特徵是否降低預測誤差 (b)、事件特徵能挽回多少誤差 (c)

整體成績由基準線 naive 的 13.44%、seasonal naive 的 9.88%，一路推進到逐站 OLS 4.83%、LightGBM 4.63%、SARIMAX 4.34%、LSTM 3.99% (test 期 WAPE)。但比排名更重要的是四項發現：(1) 沒有任何模型處處最好——LSTM 整體最佳，卻只在 54/119 站優於逐站 SARIMAX，且在住宅型與就業極端型輸給它。勝負與站點量體確有相關 (最大四分位勝率 25/30，最小四分位僅 8/30，反映全域與逐站模型的結構性分工)。(2) OD 路網特徵提供真實量體資訊，消融後整體退步 0.362pp，其中就業極端型達 0.663pp，為住宅型的 3.5 倍。(3) 極端節日出現世代反轉：春節與元旦皆由逐站 SARIMAX 勝出 (15.35% / 12.39%，對照 LightGBM 20.52% / 28.27%)，因其節日係數逐站客製，而全域模型的稀有旗標因訓練樣本過少難以穩定學習 (春節、跨年、颱風三個旗標的 SHAP 佔比合計僅 0.73%)。(4) 事件旗標的效果取決於訓練期是否經歷過該事件，而非經歷次數。訓練期未出現過該旗標值時，樹模型無法對未見過的旗標值建立切分，有無旗標的預測完全相同；只要經歷過一次以上，即可消除七至八成誤差。

將上述發現轉為實務治理建議：捷運公司可按站型配置工具——住宅型與就業極端型用逐站 SARIMAX 即可，觀光 / 就業型場站則選用進階模型 LSTM global。若以維護成本為優先，改用單一 LSTM global 覆蓋全網 119 站亦屬可行，代價僅在就業極端型較為明顯 (LSTM global 3.60% 對 SARIMAX 3.17%)。其次，極端事件日不應依賴任何模型的點預測，颱風是三個世代模型共同的失敗日。而在特徵表中加入大型活動日期有望改善誤差，例子是無旗標的新北耶誕城開幕，造成 BL 板橋站連續三天約 7% 的系統性低估。

1. 研究動機與研究問題

1.1 研究動機

我對臺北捷運人流分析的興趣，源自大學課程中一次單站進出站量的時間序列分析作業。從單一車站的歷史資料中，觀察到人流具有明顯的週期性，也開始好奇當分析範圍從單一車站擴展到整個捷運路網，不同車站的特性是否會影響模型的選擇？

此外我也學習了機器學習與深度學習，於是希望將不同課程中所學的方法放入同一個實際問題中，比較統計模型、機器學習與深度學習的表現。

因此，我將原先的單站分析延伸為全路網的臺北捷運人流預測研究，從大規模資料處理、特徵工程與模型建立，到模型評估、可解釋性與事件分析，建立完整的資料分析流程。並且希望透過這個專案回答的不只是「哪個模型最好」，而是進一步解釋不同車站為何適合不同方法，以及模型在什麼情況下會失效。

1.2 研究問題

(a)：不同站型（住宅 / 就業 / 就業極端 / 轉運觀光）上，統計模型與 ML/DL 模型的相對優勢是否不同？

(b)：在控制歷史進站量與日曆特徵後，加入 OD 路網特徵是否能降低車站進站量的預測誤差？（以特徵消融實驗驗證）

(c)：事件日（颱風）的預測誤差結構為何？事件特徵能挽回多少誤差？

將研究結果轉換為治理建議，捷運公司不必對 119 站使用同一套昂貴模型，可按站型配置合適的工具，並明確知道哪些日子不該信任模型。

2. 資料來源與清理

2.1 資料來源與範圍

主資料為臺北市資料大平臺的「臺北捷運各站分時進出量統計 OD」，每筆紀錄為「日期 × 小時 × 進站站 × 出站站 → 人次」。資料範圍為 2023 年 1 月 ~ 2026 年 5 月（41 個月、1,247 天、119 站、約 3.41 億筆），避開 2020–2022 年，排除疫情期間對運量的影響。輔助資料為政府行政機關辦公日曆表（假日、補班、春節）與臺北市天然災害停止上班上課紀錄（颱風停班 6 天），都是事前可得的官方公告。

原始 CSV 共 12.4GB，逐月下載、清理後轉為 parquet 格式（207MB）節省空間，並且驗證筆數、日期範圍正常。此外，由於資料量大，過程中以 DuckDB 對檔案直接下 SQL。

2.2 資料清理結果

（1）環狀線移交造成的雙重斷點。2023 年 6 月，資料同時出現兩個斷點。出站側：環狀線 14 站的出站紀錄消失。進站側：同 14 站出現永久性水準下移，幅度差異極大——以中山、市政府、台北車站三站估計同期季節性基準（-3.4%），扣除季節後，純環狀 11 站掉 42.0-67.3%，兼具其他路線的雙線 3 站（大坪林、景安、頭前庄）僅掉 11.4-16.9%。最關鍵的發現是：純環狀站的掉幅並非 100%，移交後仍保留三至五成的進站量。

斷點時點與環狀線 14 站營運移交新北捷運一致。推測本資料為北捷自身的 OD 帳本、移交後僅保留有經過北捷路網的旅次。完全在環狀線內完成的旅次改由新北捷運記錄，故自資料中消失。而自環狀站進站後轉乘進北捷路網者（如大坪林→板橋→頂埔）仍被計入，可以解釋進站量下移但並未歸零。雙線 3 站掉幅遠小於純環狀 11 站也與此推測一致，其客流本就有相當比例使用其他北捷路線，掉幅大小可視為該站客流中北捷路網佔比的粗略指標。

因此，本專案以進站量而非出站量為預測目標：出站側是資料完全消失，無標的可預測；進站側僅為水準下移，序列連續且仍保有三至六成量體，可正常建模。斷點位於訓練期前端

（2023-06），其後 31 個月與整個測試期均處於同一制度下，模型不會跨制度學習。

表 1 環狀線移交前後進站量變化（2023-05 → 2023-06，已扣除季節性基準 -3.4%）

群組	代表站	扣季節後真實掉幅
對照（非環狀）	中山	-0.3%
對照（非環狀）	台北車站	+0.2%
雙線 3 站	景安（橘線 + 環狀）	-11.4%
雙線 3 站	大坪林（綠線 + 環狀）	-15.4%
雙線 3 站	頭前庄（橘線 + 環狀）	-16.9%
純環狀 11 站	幸福	-42.0%

純環狀 11 站	中和	-46.8%
純環狀 11 站	新北產業園區	-58.6%
純環狀 11 站	新埔民生	-66.8%
純環狀 11 站	Y 板橋	-67.3%

(2) 0403 花蓮地震停駛。地震後板橋站至中和站間停駛 252 天，特徵表以 service_suspended 旗標標記。

(3) 跨年通宵營運。每年 12/31~1/1 跨年夜捷運連續營業 42 小時。此外，跨年夜運量達 295 萬人次，平日約為 215 萬。

3. 探索性分析：車站有「個性」

3.1 系統日運量與極端值




圖 1 系統日運量趨勢 (2023-01 ~ 2026-05)：極端值皆有事件解釋

41 個月平均日運量約 203 萬人次，平日均量 215.5 萬、週末 172.9 萬 (平日的 80.2%)。高峰前三名為兩個跨年夜 (295.2 萬、292.6 萬) 與 2025-11-14 新北耶誕城開幕日 (266.4 萬)；低谷前三名為康芮、凱米、山陀兒三個颱風停班日，成為第 8 節事件分析的素材，也證實了颱風假特徵的必要性。




圖 2 平日雙尖峰 (早 8 時、晚 18 時) vs 週末單一高原

3.2 站點功能分群




圖 3 以分時進站曲線形狀做 k-means 分群 (k=4)：住宅型、就業型、就業極端型、轉運觀光型

為回答研究問題(a)：不同站型上，統計模型與 ML/DL 模型的相對優勢是否不同？做 k-means 分群，以訓練期資料計算，將站點分成四種類型。首先，取每站平日與週末各 21 個時段的日均進站量（正常營運時間下，凌晨 02-04 時無班次），共 42 維，將每站的 42 個值除以其總和算出每小時的人流量佔比，目的是避免各站量體大小不一，在計算歐式距離時受到影響。分群結果為：住宅型 46 站（早尖峰顯著，如新埔、頂溪）、就業型 28 站（晚進站尖峰，如西門、市政府）、就業極端型 7 站（單一晚峰，如港墘、西湖）、轉運觀光型 38 站（周末權重高，如台北車站、淡水）。

3.3 OD 網絡結構




圖 4 OD 累計流量熱圖（進出站量前 40 大站，log10 尺度）：流量高度集中於台北車站




圖 5 前 15 大 OD 站對與站點網絡中心性：PageRank 與累計進站量近乎線性 (Spearman $\rho = 0.996$)

累計 OD 矩陣高度集中，且集中的形式相當單一：前 15 大站對無一例外皆以台北車站為一端，其中七組是同一組站對的來回雙向（西門、市政府、台北 101/世貿、中山、忠孝復興、忠孝新生）；第一組不含台北車站的站對要排到第 19 名（市政府→南港，382 萬人次）。最大單一站對為西門→台北車站（累計 945 萬人次），且方向明顯不對稱——反向的台北車站→西門為 884 萬，少 6.5%。此種不對稱在通勤時段尤為明顯。

以 OD 總流量建有向加權圖計算 PageRank (damping factor: $d=0.85$ ，即隨機旅客延續搭乘的機率；而 $1-d=0.15$ 為隨機傳送至任一站的機率)，前八名為台北車站、西門、市政府、中山、忠孝復興、南京復興、BL 板橋、松江南京。但從圖中發現 PageRank 與累計進站量的排序幾乎完全重合 (Spearman $\rho = 0.996$ 、Pearson $r = 0.998$)，圖 5 右側散布圖呈現似線性的關係，沒有「網絡位置價值明顯高於自身進出量」的站。推測因為捷運 OD 圖過於稠密且

流量高度集中於台北車站，因此在資料中，它主要承載的是站點量體，而非量體以外的拓撲資訊。

另外，分時 OD (站對 × 時段 × 日) 約 39% 的組合為零流量；若不分時段，全期加總後的站對組合皆不為零流量。此稀疏性顯示 OD 級預測需採用處理稀疏計數的方法，因此以站級日進站量為預測目標。

註：為刻畫路網的整體結構，本節的 OD 網路結構描述使用完整資料範圍 (1,247 天) ；第 4 章建模所用的網絡特徵則僅以訓練期 (2023-01-01 ~ 2024-12-31) 計算。

4. 特徵工程、評估方式與防洩漏設計

4.1 特徵表

特徵表共 148,393 列 (119 站 × 1,247 天) × 27 欄。因 roll28_mean 需要 28 天回溯期，各站前 28 天的動量特徵為空值，建模時整列剔除 (119 × 28 = 3,332 列)，實際訓練與評估使用 145,061 列，涵蓋 2023-01-29 ~ 2026-05-31。特徵分四類：日曆線索 (星期、月份、周末、補假、補班、春節、颱風停班停課、跨年) ；動量線索 (lag1 / lag7 / lag14、7 日與 28 日移動平均，先 shift(1) 再計算) ；車站個性 (四類站型標籤、PageRank、累積進出流量、度數) ；特殊旗標 (環狀線、地震停駛)。

4.2 評估方式 (三世代統一)

表 2 資料切分 (所有模型共用)

資料段	期間	用途
train	2023-01-29 ~ 2024-12-31	訓練集
validation	2025 全年	驗證集，挑選模型參數
test	2026-01-01 ~ 2026-05-31 (151 天)	測試集

使用一步預測 (one-step-ahead)：預測第 t 日可用 t-1 (含) 以前的所有真實觀測值，模擬捷運公司每天下班後預測明天的使用情境。主指標為 WAPE ($\sum|\text{誤差}|/\sum \text{實際值}$)：不採 MAPE 是為了避免小站單日誤差過大，使 MAPE 被過度放大。用驗證集調整參數後，以訓練集+驗證集重新訓練模型，最後用測試集測試。

4.3 防數據洩漏守則

(1) 所有 lag / rolling 特徵先 shift(1) 再計算，不含當日資訊；(2) 站點靜態特徵 (分群、PageRank、流量強度) 只用訓練期資料計算；(3) 事件旗標採事前可得的官方公告 (颱風停班為前一晚人事行政總處公布) 。

5. 三世代模型

5.1 統計世代：基準模型、逐站 OLS 與 SARIMAX

先立四個基準模型 (Baseline Model)：naive (明天 = 今天，WAPE 13.44%)、seasonal naive (明天 = 上週同日，9.88%)、rolling28 (28 日均，15.83%)、逐站 OLS 線性迴歸 (星期 + 假日旗標 + 動量特徵，4.83%)。從上述結果可看出 seasonal naive 大幅優於 naive，週季節性是主要規律，而逐站迴歸模型結合多個時間特徵表現較佳。

針對時間序列資料，逐站各建一個 SARIMAX(1,0,1)(1,1,1)₇ 模型，共 119 個：用 7 天的季節差分抓星期節律，另外加入假日 / 春節 / 跨年 / 補班四個 0/1 變數處理日曆效應。測試期不重新訓練模型，每天以截至前一天的實際資料預測隔天 (one-step-ahead)，WAPE 4.34%，119 站全部收斂。因本資料週季節性較強，故選 $s = 7$ ，但並未用 ACF/PACF 選擇參數 (order selection)。因此 SARIMAX 是本專案唯一未調參的模型，4.34% 應視為保守預估，調參後可能更低。

5.2 機器學習世代：全域樹模型

與統計世代「一站一模型」不同，機器學習世代訓練單一全域模型：不給站名，站別資訊只以站型標籤 + 網絡靜態特徵表達，讓模型學各站型的規律。這個設計是為了回答研究問題 (a)，若模型靠站型即可預測得好，「按站型配置工具」就是可行的。主力 LightGBM WAPE = 4.63% (validation 選出 num_leaves=127、min_child_samples=50、lr=0.05、n=511)，此外 RandomForest WAPE = 4.62% (max_depth 不設限、min_samples_leaf=5、n_estimators=300)。

5.3 深度學習世代：LSTM global

LSTM 直接閱讀每站近 28 天原始序列 (進站量 z-score + 實際放假日 + 國定假日三通道)，搭配 26 維目標日情境 (星期 one-hot 7 維、月份 sin/cos 2 維、六個日級事件旗標、停駛旗標、站點靜態特徵 5 維、站型 one-hot 4 維、環狀線旗標) 與 12 維可學習的 station embedding。

三組架構以 validation 早停比較，選出 hidden=128 單層 (val WAPE 3.917%)，以 train+val 重訓 24 epochs 後測試集只評一次；CPU 訓練約 15–20 分鐘，seed 固定。值得注意的是 LSTM 透過 embedding 有站身分，與樹模型無站名不同，embedding 是模型自動學習的站型特徵，與人工給定的站型 / 網絡特徵互補。

6. 結果：三世代比較與站型分析

6.1 主結果

表 3 累積比較表 (test 2026/01–05、一步預測、WAPE，越低越好)

模型	世代	整體	住宅型 (46)	就業型 (28)	就業極 端型(7)	觀光型 (38)
rolling28 (抄月均)	基準	15.83%	15.36%	16.34%	35.80%	13.63%
naive (抄昨天)	基準	13.44%	13.45%	13.75%	25.07%	11.95%
seasonal naive (抄上 週)	基準	9.88%	8.70%	10.45%	13.23%	9.84%
逐站 OLS ×119	統計	4.83%	4.17%	4.95%	5.34%	5.15%
LightGBM global	ML	4.63%	3.93%	4.62%	4.26%	5.20%
RandomForest global	ML	4.62%	3.72%	4.71%	4.45%	5.21%
SARIMAX 逐站 ×119	統計	4.34%	3.23%	4.62%	3.17%	5.02%
LSTM global	DL	3.99%	3.29%	3.97%	3.60%	4.55%

若按世代排序，基準線 9.88% → 統計世代 4.83% / 4.34% → ML 世代 4.62 / 4.63% → DL 世代 3.99%，統計世代的 SARIMAX 反而優於整個 ML 世代，可見模型越複雜預測未必越好。

6.2 站型 × 世代：研究問題 (a) 的四組證據

研究問題 (a)：不同站型 (住宅 / 就業 / 就業極端 / 轉運觀光) 上，統計模型與 ML/DL 模型的相對優勢是否不同？

從上方表 3 中可以發現**沒有任何一個模型處處最好**。住宅型與就業極端型，由逐站 SARIMAX 勝出，連整體最佳的 LSTM 都輸。這兩型的通勤節律最規則，住宅型天天早尖峰，就業極端型天天單一晚尖峰，幾乎不變，SARIMAX 的週季節設定剛好對上這種資料。第二，就業型是三個世代最接近的地方：SARIMAX 與 LightGBM 同為 4.62%，只有 LSTM 拉開差距（3.97%）。第三，觀光型在統計與 ML 世代全部卡在 5.02~5.21% 的區間，唯有 LSTM 降到 4.55%。主因為這型站的人流受活動、天氣、連假影響大，規律性最差，光靠日曆與動量特徵不夠，缺少大型事件資訊。第四，就業極端型跨世代的跨度最大，選擇適合的方法能大幅降低誤差。LSTM 雖為整體表現最佳，但只在 54/119 站優於 SARIMAX，能贏得整體最佳是因為這 54 站占了 66.2% 的總運量，按站點大小拆開看：

表 4 依測試期運量四分位拆解 LSTM 與逐站 SARIMAX 的勝負（WAPE%）

運量四分位數	LSTM 勝出站數	平均 LSTM	平均 SARIMAX
Q4(最大 30 站)	25/30	4.23%	4.85%
Q3	16/29	3.48%	3.49%
Q2	5/30	4.00%	3.93%
Q1(最小 30 站)	8/30	5.41%	4.84%

大站由 LSTM 勝出、小站由逐站 SARIMAX 勝出，反映全域模型的損失涵蓋全部 119 站，模型容量會向貢獻多數運量的大站靠攏；小站在全域模型訓練中樣本權重低，反而是逐站模型的主場。

6.3 消融實驗：路網特徵的價值（研究問題 b 的答案）

表 5 網絡特徵消融實驗（LightGBM，移除 PageRank / 流量強度 / 度數後重新調參重訓）

站型	完整特徵	移除網絡特徵	退步（pp）
整體	4.634%	4.996%	+0.362
住宅型(46)	3.932%	4.120%	+0.188
就業極端型(7)	4.263%	4.926%	+0.663
就業型(28)	4.623%	5.037%	+0.414

觀光型(38)	5.203%	5.613%	+0.410
---------	--------	--------	--------

研究問題 (b)：在控制歷史進站量與日曆特徵後，加入 OD 路網特徵是否能降低車站進站量的預測誤差？(以特徵消融實驗驗證)

結論為能降低預測誤差。移除網絡特徵整體退步 0.362pp，其中就業極端型退步最重 (0.663pp，為住宅型 0.188pp 的 3.5 倍)。由於 LightGBM 為不含站名的全域模型，雖然保留站型標籤，但站型標籤主要描述「何時搭車」的需求型態，無法反映「有多少人」的量體差異。以就業極端型為例，7 個站的日均進站量有差異，卻共用相同的站型標籤；網絡特徵則正好補足了這項量體資訊。此外，就業極端型僅占全網 3.6% 的進站量，在全域訓練中的樣本權重較低，若缺少穩定的靜態資訊作為輔助，模型較難僅依靠動量特徵充分學習該站型。相較之下，轉運觀光型雖然內部量體差距更大 (175 倍)，但因站數與整體量體均較充足，模型仍能從動量特徵中學習，因此移除網絡特徵後僅退步 0.410pp。總結而言，**網絡特徵的價值在於補足站型標籤缺少的量體資訊**，而站型的樣本量越少，這項資訊的重要性越高。

7. 可解釋性：模型靠什麼預測 (LightGBM x SHAP)

7.1 全域重要度




圖 6 LightGBM 全域特徵重要度 (mean |SHAP|，測試集)

LightGBM 的 SHAP 分析顯示，歷史需求特徵是模型預測的主要資訊來源。其中，lag7 的 SHAP 重要性最高，占 31.7%；lag14 次之，占 15.9%，兩者合計達 47.6%，顯示模型高度依賴一週與兩週前的歷史需求來掌握站點的週期性模式。pagerank 的 SHAP 重要性為 12.5%，排名第三，略高於 lag1 的 12.4%，顯示站點在整體網絡中的結構位置亦是 LightGBM 的重要預測資訊。換言之，模型不僅依賴站點自身的歷史需求，也利用 PageRank 所代表的網絡結構資訊辨識不同站點的角色與需求水準。

此外，稀有事件旗標在 SHAP 分析中的影響相當有限，例如 is_typhoon 僅占 0.54%、is_lny 占 0.11%、is_nye 占 0.07%，三者合計僅約 0.73%。表示在 LightGBM 中，這些特殊事件並非主要的預測訊號。其重要性偏低可能與這類事件在訓練期間出現頻率較低有關，使模型較難從有限的樣本中穩定學習其對人流量變化的影響。這也有助於解釋第 8 節中部分特殊事件效果不明顯的現象。

7.2 站型的依賴特徵




圖 7 LightGBM 不同站型依賴的特徵 (SHAP 佔比%；站型量級不同，故用佔比對照)

表 6 SHAP 佔比前五特徵 × 站型 (%，粗體 = 該列全場最高)

特徵	住宅型	就業型	就業極端型	觀光型
lag7 (上週同日)	34.5	33.8	33.8	27.1
lag14	14.3	19.2	16.3	14.6

pagerank	11.1	5.5	9.8	19.9
lag1 (昨日)	11.7	12.8	11.5	12.9
is_offday (假日)	9.1	8.8	8.8	7.5

站型的 SHAP 分析顯示，LightGBM global 在面對不同站型時依賴不同特徵。lag7 在四個站型中皆為最重要的特徵，但比重並不相同：住宅型 34.5%、就業型與就業極端型同為 33.8%，觀光型則明顯偏低，僅 27.1%。真正的不同處出現在 pagerank，其 SHAP 占比在觀光型高達 19.9%，在就業型卻僅 5.5%，相差約 3.6 倍，是前五項特徵中站型間落差最大的一項。另外可以值得注意的是它在各站型內的排序，在住宅型與就業極端型中 pagerank 排名第四，在就業型中排名最後，唯獨在觀光型中躍居第二（19.9%），超過 lag14 的 14.6% 與 lag1 的 12.9%。

SHAP 所呈現的站型差異，並未與第 6.3 節網絡特徵消融後的效能損失呈現相同排序。

LightGBM global 在預測觀光型站點時高度依賴網絡結構資訊；然而，在消融實驗中，移除網絡特徵後，退步最大的卻是就業極端型（0.663pp），而觀光型僅退步 0.410pp。主要原因為兩種分析衡量的是不同面向，SHAP 衡量的是「模型在進行預測時，該特徵對輸出的平均影響程度」，反映模型對特徵的使用強度；消融實驗則衡量「移除該特徵後模型效能下降多少」，反映該資訊的不可替代程度。

因此，觀光型雖然對網絡特徵的使用強度最高，但移除後仍可透過 lag14、lag1 等特徵部分維持原有的預測能力，因此呈現「使用程度高、但部分可由其他資訊補足」。相較之下，就業極端型的 pagerank SHAP 占比僅 9.8%，在四類站型中並不突出，但該站型僅有 7 站、量體占全網 3.6%，且進站需求集中於單一晚間尖峰，與其他站型的型態差異較大。在這種情況下，網絡特徵所提供的站點結構與量體資訊可能具有較高的獨特性，其他特徵較難完全補足，因此移除後反而造成較大的效能損失。

8. 事件日的誤差結構

8.1 test 期各日型誤差：三世代對照




圖 8 test 期各日型 WAPE：統計 vs ML vs DL

表 7 按日型 WAPE% (粗體 = 該日型最佳模型)

日型	天數	SARIMAX	LightGBM	LSTM
一般平日	97	2.98	3.13	2.79
一般週末	44	6.59	6.72	5.61
其他國定假日	5	11.10	10.43	8.45
春節 (除夕~初三)	4	15.35	20.52	20.32
元旦 (跨年翌日)	1	12.39	28.27	16.15

平日 LSTM 最佳，但極端節日出現明顯的世代反轉，例如：春節四天、元旦 SARIMAX 大幅領先，模型結構差異為主要原因。SARIMAX 採逐站建模，其春節與跨年等節日旗標的係數可針對各站點分別估計，為每站建立客製化的節日效應，因此能捕捉不同站點在特殊節日期間的個別流量變化。相較之下，全域模型在一般情境下能透過跨站共享資訊取得優勢，但這項優勢在稀有事件上反而受到限制，表現較差。

8.2 事件實驗（研究問題 c 的答案）

以下實驗使用 LightGBM 模型，將訓練資料截至事件首日前一天，模擬「事件前夕做預測」的真實情境。




圖 9 事件旗標的挽回效果 (hold-out)

表 8 颱風停班日 hold-out (WAPE% ; 分母為停班日實際運量，約平日的兩成，故數字放大)

事件	此前經歷颱風	seasonal naive	無旗標	有旗標	挽回(pp)	相對降幅 (%)
卡努 2023-08-03	0 次	272.8	294.6	294.6	0.0	-0%
凱米 2024-07-24/25	1 次	448.0	419.8	120.0	299.7	-71.4%
山陀兒 2024-10-02/03	2 次	296.5	244.8	46.9	197.9	-80.8%
康芮 2024-10-31	3 次	1089.2	1040.2	265.2	775.0	-74.5%

事件旗標的挽回效果呈「0 次 vs ≥1 次」的區別，而非隨經歷次數增長。（一）訓練期未出現過該旗標值時，樹模型無法建立切分，特徵完全無效，卡努有無旗標預測完全相同，且輸給 seasonal naïve。一旦經歷過至少一次，旗標可以減少約七至八成誤差。（二）挽回 (pp) 在事

件之間不可比，其幅度主要由該事件本身的異常程度決定。四場颱風的時長與實際影響不同，WAPE 分母（停班日實際運量）差異大。以 seasonal naive 誤差為例，康芮（1089.2%）遠高於其餘三場（272.8 / 448.0 / 296.5%），因此其挽回 pp 亦最大（+775.0pp）。

耶誕城開幕：2025-11-14 起連續三天，模型對 BL 板橋站低估 7.1% / 7.7% / 6.8%，一個可預期、有公告的大型活動，因特徵表沒有對應欄位，模型就連錯三天，若加入活動日期作為特徵，或許可以進一步提升模型的預測表現。

9. 治理洞見：從模型排名到資源配置

（1）捷運公司可按站型選擇模型。住宅型 / 就業極端型規律性較高，適合用統計模型 SARIMAX；觀光 / 就業型場站則選用進階模型 LSTM global。若以節省模型維護成本為優先，可用單一 LSTM global 模型覆蓋全網的 119 站。

（2）極端事件日不應依賴任何模型的點預測。颱風是三世代模型共同的失敗日。模型可以幫助預測「正常情況會有多少人」，管理人員再以當前情境人工判斷調整。

（3）在特徵表中加入大型活動日期。颱風日的旗標只要在訓練期出現過至少一次，即可消除 70–80% 的誤差；反之，新北耶誕城開幕因特徵表中沒有任何可標記的欄位，模型對 BL 板橋站連續三天系統性低估約 7%。推測接入活動日期帶來的效益高於模型升級。

10. 研究限制

(1) 事件特徵僅涵蓋假日 / 補班 / 颱風 / 跨年，大型活動（演唱會、展覽、運動賽事）是誤差的主要來源。

(2) 樹模型對訓練期未見過的旗標值無法外推

(3) LSTM 透過 embedding 學習站點身分，而樹模型僅使用站型分類資訊，因此兩者的站點資訊設定並不完全相同。

(4) 測試期無颱風日，颱風泛化能力以 hold-out 實驗補充而非測試期直接觀察。

11. 參考資料

- 臺北市資料大平臺：[臺北捷運各站分時進出量統計 OD](#)、[臺北市歷次天然災害停止上班上課訊息](#)

- 政府資料開放平台：[中華民國政府行政機關辦公日曆表](#)

—— 全文完 ——